FAST TRACK IA · DESAFIO 1

Quem tem mais risco de não pagar?

Análise de risco de crédito da CredAIR com Regressão Logística

Alex Lourenço · github.com/alexlourenc/CredAIR-Alex

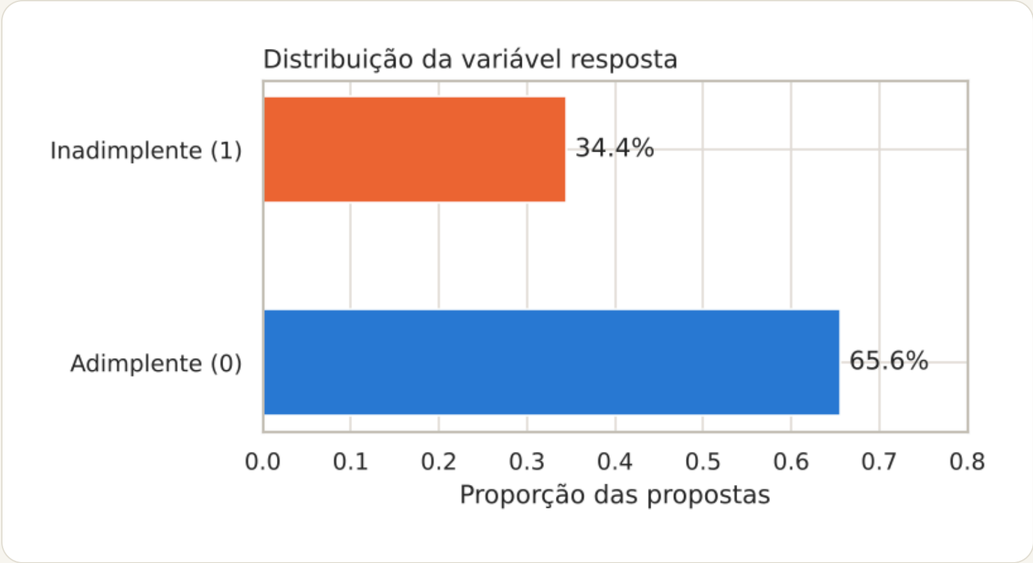
1 · O PROBLEMA

Prever quem vai ficar inadimplente

Variável resposta: **inadimplente** (0 ou 1). É uma **classificação binária supervisionada**: temos o histórico com a resposta conhecida.

Os erros não custam o mesmo. Aprovar um mau pagador custa o capital emprestado. Recusar um bom pagador custa os juros e o cliente.

Com **34,4%** de inadimplentes, chutar sempre "adimplente" acerta 66% sem aprender nada. Por isso a acurácia engana.



2 · ORGANIZAÇÃO

Dados em três camadas, um commit por fase

BRONZE

Dado bruto

O CSV exatamente como recebido. Nunca é alterado.

PRATA

Dado limpo

Tipos corretos, sem duplicatas, inconsistências tratadas.

OURO

Pronto para o modelo

Com a variável criada. Só transformações linha a linha.

Regra contra vazamento de dados

Imputação, padronização e one-hot aprendem com os dados. Por isso ficam no Pipeline e são ajustadas **só no treino**, nunca na camada ouro.

3 · QUALIDADE DOS DADOS

Diagnosticar antes de tratar

Problema encontrado	Tratamento
19 linhas duplicadas	Removidas
101 UFs com espaços (“ MG ”)	Texto padronizado
15 idades de 210 a 750 anos	Marcadas como ausentes
8 tempos de emprego ≥ idade	Marcados como ausentes
10 rendas artificiais (R$ 100 a 550)	Marcadas como ausentes

Por que não apagar a linha?

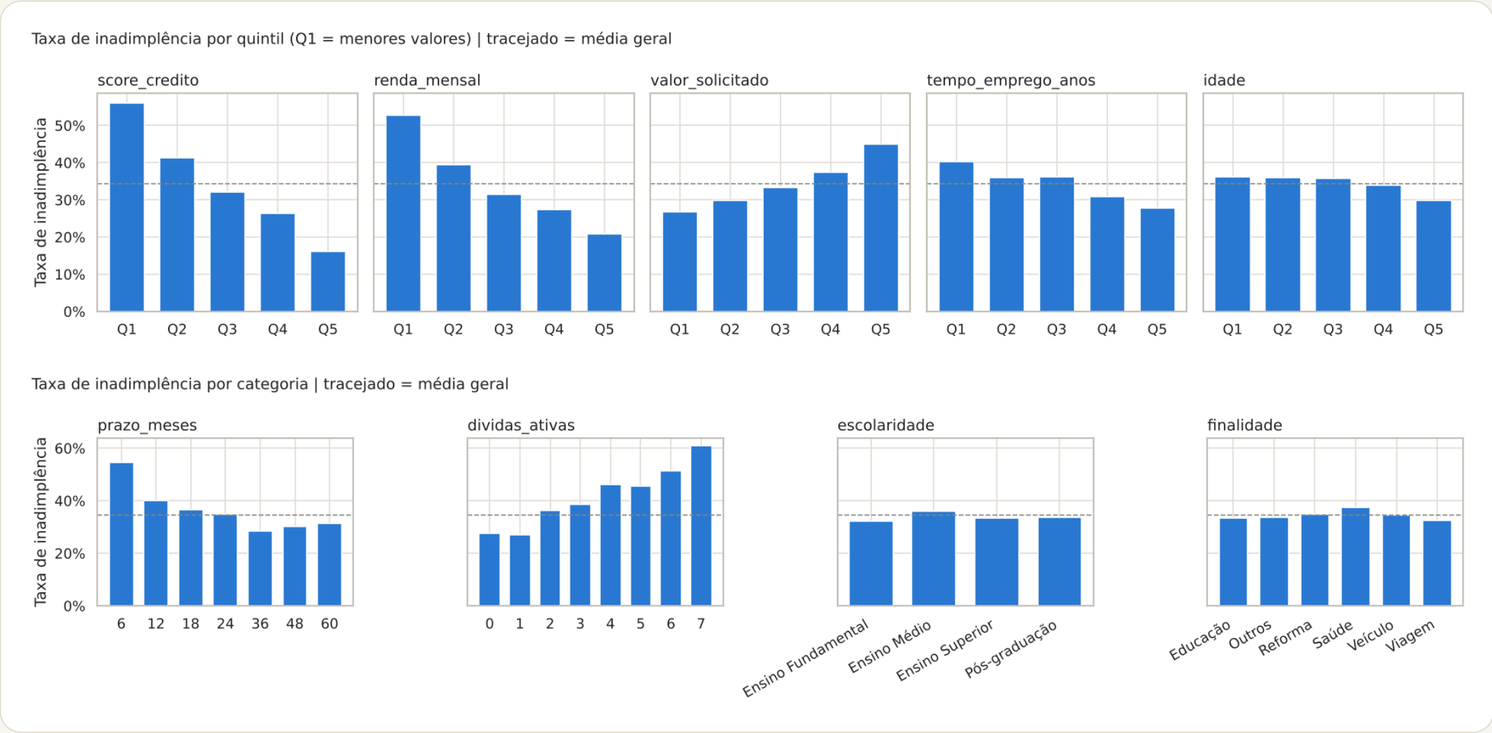
As outras colunas estão corretas. A mediana é imputada no Pipeline, só com o treino.

Por que não dividir a idade por 10?

Algumas idades corrigidas ficariam incoerentes com o tempo de emprego.

4 · ANÁLISE EXPLORATÓRIA

Score, renda e dívidas separam os grupos



Score: de 56% para 16% de inadimplência do pior ao melhor quintil.

Dívidas ativas: de 27% para 61%.

Prazo curto tem mais risco (55% em 6 meses). Contraintuitivo.

Estado, escolaridade e finalidade: sem associação (qui-quadrado, p de 0,23 a 0,60).

5 · A VARIÁVEL CRIADA

O risco não é o prazo, é o peso da parcela

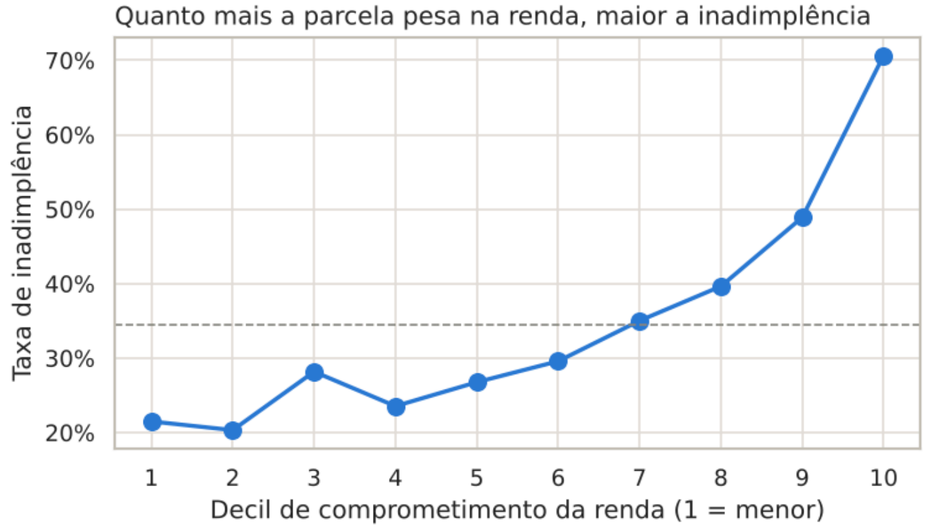
comprometimento_renda =
(valor ÷ prazo) ÷ renda

71%

de inadimplência no decil de maior comprometimento (21% no menor)

0,793

AUC na validação cruzada com a variável (0,769 sem ela)



6 · MODELAGEM

Escolha feita na validação cruzada, não no teste

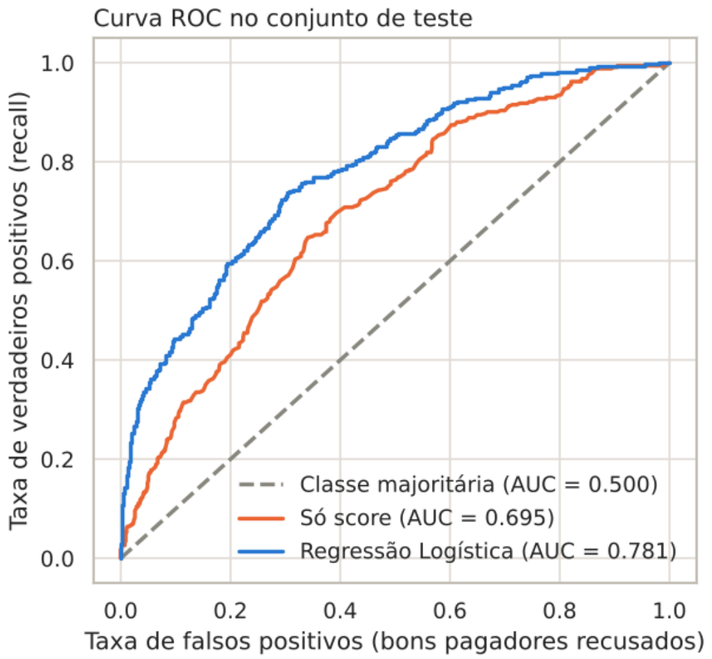
Treino e teste 80/20 estratificado. Configurações comparadas com validação cruzada de 5 partes, só no treino.

Configuração (validação cruzada, treino)	ROC-AUC média
Referência: classe majoritária	0,500
Referência: só score de crédito	0,679
Logística com as variáveis originais	0,769
+ comprometimento_renda	0,793
+ estado (descartado: pior e com risco ético)	0,788
Final: 8 variáveis numéricas	**0,794**

Sem escolaridade e finalidade o resultado é o mesmo, então ficou o modelo mais simples (parcimônia).

7 · RESULTADOS NO TESTE

AUC de 0,781 em dados nunca vistos



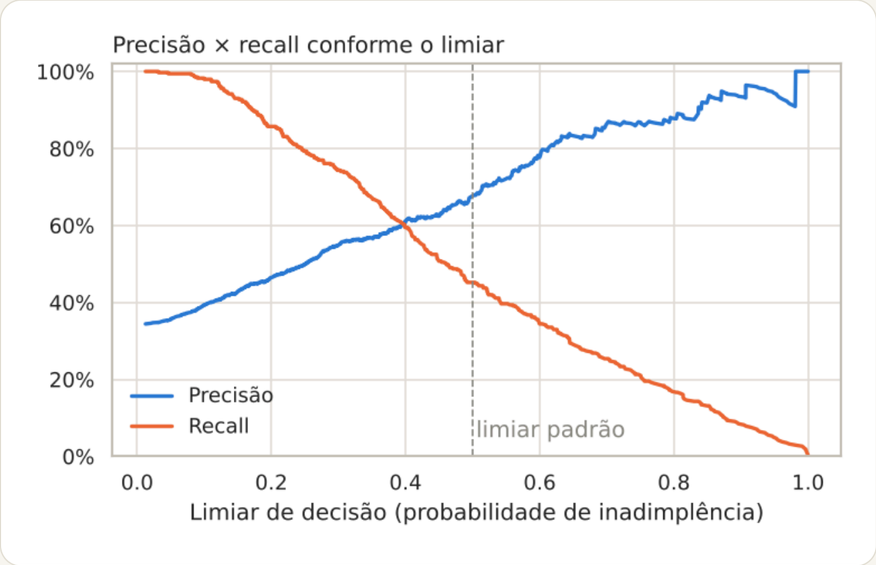
Conjunto de teste	ROC-AUC	Recall
Classe majoritária	0,500	0%
Só score de crédito	0,695	24%
Regressão Logística	**0,781**	**45%**

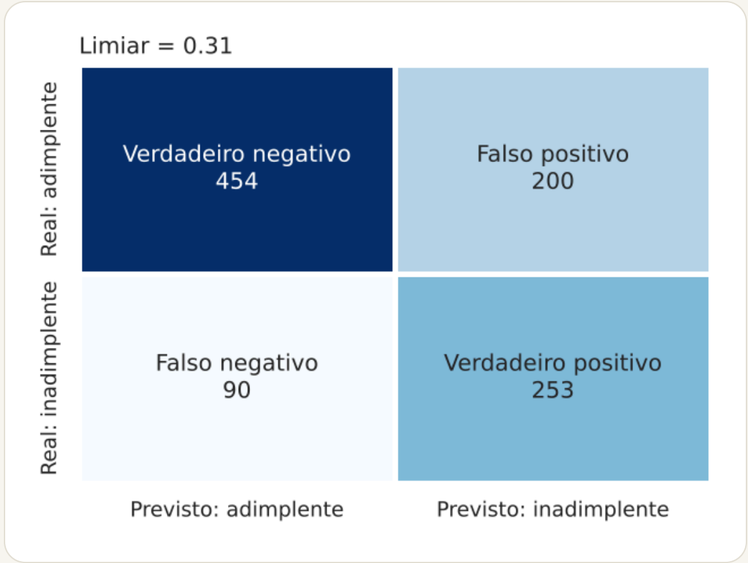
O teste (0,781) fica perto da validação cruzada (0,794, desvio ±0,016): o modelo **generaliza**, sem sinal de sobreajuste.

Recall no limiar padrão de 0,5. A referência só com score marca 0,68 na validação cruzada e 0,695 aqui, no teste.

8 · LIMIAR DE DECISÃO

Com limiar 0,31, o modelo pega 74% dos inadimplentes





Recall: **45%** → **74%**

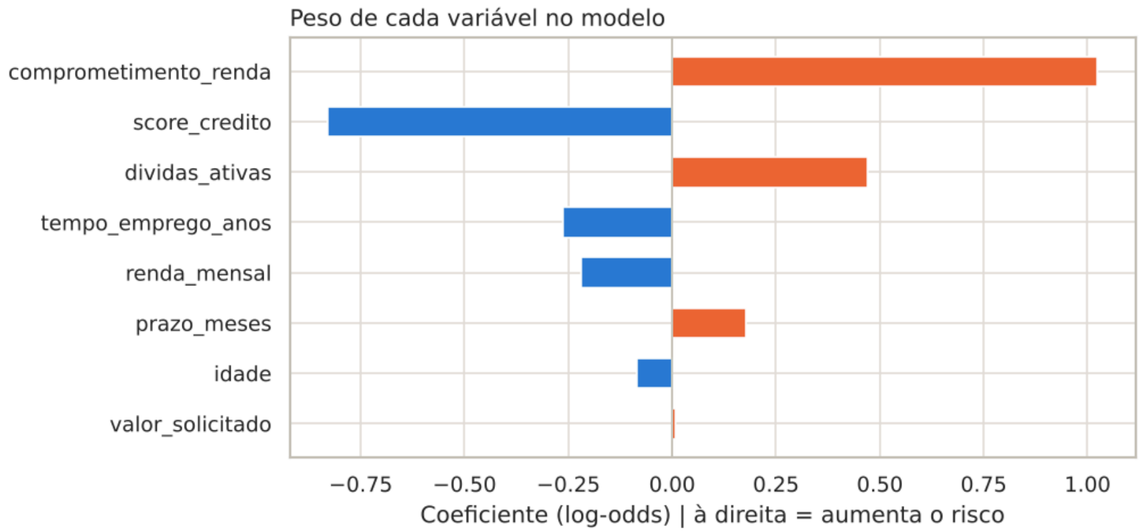
Precisão: **68%** → **56%**

Limiar escolhido no treino (F1 máximo), não no teste.

O limiar é uma **decisão de negócio**: os casos sinalizados vão para análise manual ou condições ajustadas, não para recusa automática.

9 · INTERPRETAÇÃO

O que mais pesa no risco



2,78×

comprometimento da renda: o fator de **risco** mais forte

0,44×

score de crédito: o fator de **proteção** mais forte

Dívidas ativas: 1,60×

Odds ratio por desvio-padrão. O prazo inverte o sinal no modelo: o efeito do prazo curto era, na verdade, o da parcela pesada.

10 · CONCLUSÃO

Ajustar prazo ou valor reduz o risco

O que aprendemos

- Peso da parcela na renda é o maior fator de risco
- Score é a maior proteção
- AUC 0,781 e recall de 74% no teste
- Para clientes no limite: prazo maior ou valor menor

Limitações

- Dados sintéticos
- Viés de seleção: só propostas analisadas
- Parcela calculada sem juros
- Nenhuma dimensão temporal

Cuidados no uso real

- O modelo apoia, não decide sozinho
- Justiça e LGPD
- Monitorar mudanças e retreinar
- Mesmas regras de limpeza do treino

ALÉM DO DESAFIO

Do notebook a um simulador que qualquer um testa

Pacote credair

As regras validadas no notebook viraram módulos Python. O notebook importa o mesmo código.

27 testes automáticos

Conferem cada regra de limpeza e se o modelo reproduz AUC 0,781 e limiar 0,31. Rodam no GitHub a cada push.

Simulador online

Informa uma proposta e mostra a probabilidade, a decisão e o que mais pesou.

cred-air-alex.vercel.app · github.com/alexlourenc/CredAIR-Alex